

# ENTROPIA

- **entropia**

- valoarea medie de informației primită despre o variabilă X

$$H(X) = E(I(X)) = \sum_{i=1}^N p_i \log_2 \frac{1}{p_i} = \sum_{i=1}^N -p_i \log_2 p_i$$

- $H(X)$  se numește entropia lui X
- $I(X)$  este informația despre X
- $E$  este “expected value”, operația care calculează valoarea medie
- exemplu:  $X = \{A, B, C, D\}$  cu probabilități  $\{1/3, 1/2, 1/12, 1/12\}$


- $H(X) = -\frac{1}{3} \log_2 \frac{1}{3} - \frac{1}{2} \log_2 \frac{1}{2} - \frac{1}{12} \log_2 \frac{1}{12} - \frac{1}{12} \log_2 \frac{1}{12} = 1.626$  biti
- variabila X are 4 opțiuni, deci în mod normal am avea nevoie de 2 biți să memorăm toate posibilitățile, dar (pentru că probabilitățile nu sunt egale) putem să codăm mai bine de 2 biți

# CODAREA DATELOR

- cum atingem acel 1.626 biți pentru cele patru evenimente?
- folosim o codare diferită de cea standard
  - codarea standard A = 00, B = 01, C = 10, D = 11
  - cu această codare avem ABBC = 00 01 01 10
  - decodarea este directă: luăm câte 2 biți și fiecare e un eveniment
- o altă codare (mai eficientă):
  - dimensiune variabilă a codului: A = 01, B = 1, C = 000, D = 001
  - acum avem ABBC = 01 1 1 000
  - acum sunt 7 biți, față de 8 înainte (deci e mai bine)
  - decodarea trebuie să fie unică! trebuie să ne putem întoarce
- o altă codare (și mai eficientă, dar incorectă):
  - dimensiune variabilă a codului: A = 1, B = 0, C = 10, D = 11
  - acum avem ABBC = 1 0 0 10
  - 5 biți, și mai bine
  - problema? decodarea: dacă primim 10010 cum îl decodăm?
    - ABBC sau CBC sau ...


# CODAREA DATELOR

- cum putem crea o codare eficientă și unică?
  - un arbore binar
    - frunzele sunt codurile
    - stânga/dreapta e decis de 0/1
    - codarea este:
      - $B = 0$
      - $A = 11$
      - $C = 100$
      - $D = 101$
    - asta garantează codare eficientă și decodare unică
  - cum generăm codarea eficientă?
    - algoritmul Huffman
    - input: probabilitatea fiecărui eveniment  $\{1/3, \frac{1}{2}, 1/12, 1/12\}$
    - output: codurile care se citesc de pe un arbore binar (mai sus)
    - cheia: unele evenimente/simboluri apar mai des decât altele, deci acestea primesc o codare mai scurtă
    - dacă toate evenimentele sunt equiprobabile, atunci nu putem face nimic



# CODAREA DATELOR


- cum putem crea o codare eficientă și unică?
  - un arbore binar
    - frunzele sunt codurile
    - stânga/dreapta e decis de 0/1
    - codarea este:
      - $B = 0$
      - $A = 11$
      - $C = 100$
      - $D = 101$
    - asta garantează codare eficientă și decodare unică
  - exercițiu: decodați 0 0 100 11 101 0 0 11
    - soluția: BBCADBBA



# CODAREA DATELOR

- cum putem crea o codare eficientă și unică?

- un arbore binar
  - frunzele sunt codurile
  - stânga/dreapta e decis de 0/1
  - codarea este:
    - $B = 0$
    - $A = 11$
    - $C = 100$
    - $D = 101$
  - asta garantează codare eficientă și decodare unică



- exercițiu: cum calculăm eficiența acestei codări? dimensiunea în medie a unui mesaj este? probabilitățile sunt  $\{1/3, 1/2, 1/12, 1/12\}$ 
  - $2 \times 1/3 + 1 \times 1/2 + 3 \times 1/12 + 3 \times 1/12 = 1.667$  biți
  - comparat cu 1.626 biți care e optim